

Lorem Ipsum Dolor

簡易的な医療 画像分類モデル作成

DIVE INTO CODE

7月期生


森 修弥

概要

- 近年、高齢化に伴い医療分野では多くの課題が顕在化してきた。
- 例えば、医療費による国費の圧迫や医師不足。
- そんな中で、個人の予防意識向上や病気の早期発見による負担軽減が望まれる。



一般人がある程度自分で判断することができれば
予防意識の向上や早期発見につながる可能性がある。



そこで今回は、手の画像を分析・分類し病気を
判断する機械学習モデルの構築を試みた



通常



ヘバーデン結節




関節リウマチ

Googleの画像検索から取得した手の画像を用いた

モデル

VGG16, VGG19, ResNet50, MobileNetV2を転移学習して、ファインチューニングした。



CNNで分類する方法と、
CNN+SVMで分類する方法の
2パターン試した。

SVM

正常
ヘバーデン結節
関節リウマチ

モデルの判断

機械学習モデルを構築するにあたって医療分野ならではの問題を考慮する必要がある。
下の表で、赤枠の中は実際は病気であるにも関わらず重症度が低く予測されている。

例		予測		
		正常	へバーデン結節	関節リウマチ
実際の状態	正常	6	0	0
	へバーデン結節	4	4	1
	関節リウマチ	3	3	3

そこで、評価指標として通常の正解率(accuracy)に加え
軽症だと誤判断する割合の評価指標(custom_metrics)を3つ作成した。

損失関数として、"categorical_crossentropy", "binary_crossentropy"に加え、
custom_metricsを基にした損失関数(custom_loss)を作成し、試した。

評価指標

custom_multi

$$\left(\frac{\text{予測:通常}}{\text{実際:へバーデン結節}} \times \frac{\text{予測:通常} + \text{実際:へバーデン結節}}{\text{実際:関節リウマチ}} \right)$$

custom_plus

$$\left(\frac{\text{予測:通常}}{\text{実際:へバーデン結節}} + \frac{\text{予測:通常} + \text{実際:へバーデン結節}}{\text{実際:関節リウマチ}} \right)$$

custom_precision

$$\frac{1}{3} \left(\frac{\text{TP}}{\text{TP} + \text{FP} + \text{FP}} + \frac{\text{TP}}{\text{TP} + \text{FP} \times 1.5 + \text{FP}} + \frac{\text{TP}}{\text{TP} + \text{FP} \times 2 + \text{FP} \times 1.2} \right)$$

N

H

R

結果







CNN

SVM

	CNN_acc	CNN_cus_multi	CNN_cus_plus	CNN_cus_precision	SVM_acc	SVM_cus_multi	SVM_cus_plus	SVM_cus_precision
categorical								
VGG16	0.7687	0.0150	0.2100	0.7396	0.7691	0.0100	0.1900	0.7324
VGG19	0.7698	0.0100	0.2100	0.7495	0.7350	0.0100	0.2500	0.7117
ResNet50	0.5943	0.0158	0.2417	0.5496	0.6473	0.0000	0.1267	0.6122
MobileNetV2	0.6386	0.0231	0.3094	0.5811	0.6053	0.0125	0.3267	0.5484
平均	0.6929	0.0160	0.2428	0.6549	0.6892	0.0081	0.2233	0.6512
binary								
VGG16	0.6907	0.0225	0.2994	0.6592	0.7169	0.0150	0.2794	0.6782
VGG19	0.7691	0.0175	0.2350	0.7410	0.7684	0.0175	0.2150	0.7433
ResNet50	0.6912	0.0050	0.1544	0.6307	0.6911	0.0050	0.1989	0.6332
MobileNetV2	0.7350	0.0050	0.1572	0.6847	0.7086	0.0125	0.2594	0.6557
平均	0.7215	0.0125	0.2115	0.6789	0.7212	0.0125	0.2382	0.6776
custom_loss								
VGG16	0.3350	0.4967	1.2883	0.3476	0.4224	0.0000	0.0200	0.3338
VGG19	0.3705	0.4392	1.2456	0.3747	0.4224	0.0000	0.0400	0.3346
ResNet50	0.5689	0.0406	0.4994	0.5332	0.5012	0.0181	0.2744	0.4282
MobileNetV2	0.4137	0.1883	1.0361	0.4045	0.4493	0.0000	0.3844	0.4094
平均	0.4220	0.2912	1.0174	0.4150	0.4488	0.0045	0.1797	0.3765

VGG19の”categorical_crossentropy”が最も正解率が高かった。
custom_plus/multiでは損失関数を自作し、かつSVMを通すことで改善できた。

考察



今回のタスクではVGGモデルの方が精度が高い傾向にある。

モデル単位で見れば”categorical_crossentropy”で高い正解率を示しているが平均値を見ると”binary_crossentropy”の方が高い。

今回はStratfiedKFold(n_splits=5)の平均値をそれぞれの値としているが、データ数が変わったり splitsの回数を増やすと”binary_crossentropy”の方が高くなるかもしれない。

まとめ

- VGG19-“categorical_crossentropy”で正解率75%程度だった。
- 損失関数を作成し、SVMを通すことでcustom_metricsを0.02にすることができた。
- タスクによって評価指標や損失関数を考慮し、場合によっては変更も重要である。

• 今後の課題

1) データセットの数と取得方法が正確性に欠ける。

→本来であれば、医療機関と協力し多くの画像を得る必要がある。

2) 評価指標がそもそも異なる可能性がある。

→専門知識を持つ人の協力が必要である。

3) 精度が低い。

→医療分野での発展がめざましいため、最新手法を試してみる。

→取得したデータの前処理を工夫し、画像の条件を厳しくする。

4) 細かい重症度を考慮に入れていない。

→回帰分析でやってみる

展望

- ・医療分野においては、様々な技術が用いられ、それぞれがめざましい発展をしている。
- ・セグメンテーションで、U-netにリカレント層を加えたものなどモデルの拡張をしている。
- ・GANでのデータの増強や病変部位の特定など画像認識以外の技術を医療用に応用している。
- ・そして、それら医療画像専用のモデルはライブラリの構築が盛んであり、
使用することは容易になっていく。

Prof. Dr. Olaf Ronneberger

U-net開発者の一人。医療画像分野で多くの論文を書いている。



謝辞

卒業課題を進める上でDIVE INTO CODEのメンターの皆様と
同期の皆様に多大なご助言を賜りました。
厚く御礼申し上げます。

ご静聴ありがとうございました！！